

Chapter 1

Métodos estadísticos para control de procesos multivariados

1.1 Introducción:

Para la manufactura de cualquier producto o servicio, se hace necesario definir procesos, que consisten en una serie de pasos consecutivos en los que se van utilizando, materiales, métodos, mano de obra y maquinaria, todo esto para la fabricación y ensamble de productos terminados. Dentro de estos pasos existen operaciones que se les denomina críticas y que como tales son importantes para la calidad del producto.

En estas operaciones se requieren controles que permitan a los participantes en el proceso medir y tomar acciones en caso de situaciones anómalas, a este tipo de métodos se les ha denominado **control estadístico del proceso (CEP)**.

Existen herramientas dentro del CEP que se usan dependiendo del tipo de variable a manejar, estas pueden ser discretas o continuas. Se presentaran a continuación herramientas para variables continuas, primero para el caso univariable y posteriormente el caso multivariable.

1.2 Caso univariable

Generalmente, en procesos de producción controlados, observaciones de características de una pieza maquinada fluctúan alrededor de las especificaciones de calidad. Estas desviaciones con respecto a un valor medio son provocadas muchas veces por una suma de factores aleatorios tales como cambios de temperatura y de humedad, vibraciones, variaciones en el ángulo de corte, desgaste en los cojinetes, variaciones en la velocidad de rotación, variaciones de montaje y de la pieza de soporte, variaciones en las numerosas características de la materia prima y variaciones en los niveles de contaminación. Más aún, en la práctica es común encontrar que desviaciones hacia la derecha o izquierda del valor medio ocurren aproximadamente la misma cantidad de veces. Este comportamiento puede ser modelado como una distribución normal, dada las características de la misma.

1.2.1 Distribución normal

La distribución normal de una variable aleatoria X con media μ y varianza σ^2 es una distribución estadística con función de densidad de probabilidad (fdp)

$$f(x|\mu, \sigma) = \frac{1}{\sigma \sqrt{2\pi}} e^{-\frac{(x-\mu)^2}{2\sigma^2}} \quad (1.1)$$

donde $x \in (-\infty, \infty)$

De aquí en adelante una variable aleatoria normal de parámetros μ y σ sera denotada como $X \sim N(\mu, \sigma^2)$.

Notese que, si $X \sim N(\mu, \sigma^2)$ entonces la variable aleatoria $Z = (X - \mu)/\sigma$ tiene una distribución $N(0, 1)$, conocida como *normal estándar*

$$\begin{aligned} P(Z \leq z) &= P\left(\frac{X - \mu}{\sigma} \leq z\right) \\ &= P(X - \mu \leq \mu + z\sigma) \\ &= \frac{1}{\sigma \sqrt{2\pi}} \int_{-\infty}^{\mu + z\sigma} e^{-\frac{1}{2}\left(\frac{x-\mu}{\sigma}\right)^2} dx \end{aligned}$$

si sustituimos $t = \frac{x-\mu}{\sigma}$, y $dt = \frac{dx}{\sigma}$ queda

$$P(Z \leq z) = \frac{1}{\sqrt{2\pi}} \int_{-\infty}^z e^{-\frac{1}{2}t^2} dt \quad (1.2)$$

mostrando que $P(Z \leq z)$ es una *función de distribución normal estándar*.

1.2.2 Estimadores de la media y la varianza de una normal

Siendo que en procesos de manufactura no es conveniente medir cada uno de los productos fabricados, es necesario establecer planes de muestreo que permitan de una manera económica tomar decisiones sobre la población, representada aquí como la producción de un turno o un día.

Con estas muestras que por lo regular son pequeñas se calcula el promedio y la varianza con los valores de la característica estudiada de cada una de las piezas de la muestra, a continuación se grafican en una carta de control que se discutirá posteriormente en que consiste, y dependiendo de los resultados se tomará la decisión de continuar o parar la producción.

De ahí que, es necesario justificar porque a partir de los resultados de las muestras se toman éste tipo de decisiones que por lo regular involucran costos de horas hombre y maquina.

En esta sección mostraremos algunas propiedades teóricas de estos estimadores; que justifican su uso en este trabajo para el control estadístico de procesos.

Valor esperado de una variable aleatoria. Para la fines que se persiguen en esta tesis, basta definir el valor esperado de una variable aleatoria continua. Sea X una variable aleatoria continua con función de densidad de probabilidad $f(x)$, entonces el valor esperado de X ,

denotado por $E(X)$, se define por:

$$E(X) = \int_{-\infty}^{\infty} x f(x) dx \quad (1.3)$$

siempre y cuando la integral exista. De aquí en adelante se denotará a $E(X)$ como μ .

Varianza de una variable aleatoria. La varianza de una variable aleatoria se denota como $Var(X)$ o σ^2 y se define por:

$$Var(X) = E(X - E(X))^2. \quad (1.4)$$

Nótese que al desarrollar el binomio y aplicar esperanza en la ecuación 1.4 se obtiene que

$$\sigma^2 = E(X^2) - \mu^2. \quad (1.5)$$

Estimadores de la media y la varianza Los estimadores de la media y la varianza que se usarán en esta tesis se denotan como $\hat{\mu}$ y $\hat{\sigma}^2$, respectivamente, y son:

$$\hat{\mu} = \frac{1}{n} \sum_{i=1}^n x_i = \bar{x} \quad (1.6)$$

y

$$\hat{\sigma}^2 = \frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})^2 \quad (1.7)$$

donde x_1, x_2, \dots, x_n son valores observados de una variable $X \sim N(\mu, \frac{\sigma^2}{n})$ y que representan la característica estudiada.

1.2.3 Propiedades de los estimadores

Los estimadores presentados en 1.6 y 1.7 cumplen lo siguiente:

1. $\bar{X} \sim N(\mu, \frac{\sigma^2}{n})$.
2. Los estimadores $\hat{\mu}$ y $\hat{\sigma}^2$ son insesgados.
3. \bar{X} y $\hat{\sigma}^2$ son variables aleatorias independientes.

Para demostrar que $\bar{X} \sim N(\mu, \frac{\sigma^2}{n})$ se usará la función generadora de momentos (fgm) de una la variable aleatoria normal, $E(e^{tx}) = e^{\mu t + \frac{\sigma^2 t^2}{2}}$. La fgm de \bar{X} es

$$\begin{aligned}
E(e^{t\bar{X}}) &= E(e^{t \frac{1}{n} \sum_{i=1}^n X_i}) \\
&= E[(e^{\frac{t}{n}} \cdot e^{\frac{t}{n} X_2} \dots e^{\frac{t}{n} X_n})] \\
&= E(e^{\frac{t}{n} X_1}) \cdot E(e^{\frac{t}{n} X_2}) \dots E(e^{\frac{t}{n} X_n}) \\
&= e^{\mu \frac{t}{n} + \frac{\sigma^2 t^2}{2n^2}} \dots e^{\mu \frac{t}{n} + \frac{\sigma^2 t^2}{2n^2}} \\
&= e^{\mu t + \frac{\sigma^2}{2} t^2}.
\end{aligned}$$

Por lo tanto, $\bar{X} \sim N(\mu, \frac{\sigma^2}{n})$.

Para demostrar el punto 2 se procede de la siguiente forma:

$$\begin{aligned}
E(\hat{\mu}) &= E(\frac{1}{n} \sum_{i=1}^n X_i) \\
&= \frac{1}{n} E(\sum_{i=1}^n X_i) \\
&= \frac{1}{n} \sum_{i=1}^n E(X_i) \\
&= \frac{1}{n} \sum_{i=1}^n \mu \\
&= \frac{n\mu}{n} \\
&= \mu.
\end{aligned}$$

Por lo que $\hat{\mu} = \bar{x}$ es un estimador puntual insesgado de μ .

Para demostrar que $\hat{\sigma}^2$ es un estimador insesgado de σ^2 se procede de la siguiente forma

$$\begin{aligned}
E(\hat{\sigma}^2) &= E\left(\frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2\right) \\
&= \frac{1}{n-1} (E(\sum_{i=1}^n (X_i^2 - 2X_i\bar{X} + \bar{X}^2))) \\
&= \frac{1}{n-1} (E(\sum_{i=1}^n X_i^2 - 2\bar{X} \sum_{i=1}^n X_i + \sum_{i=1}^n \bar{X}^2)) \\
&= \frac{1}{n-1} (E(\sum_{i=1}^n X_i^2) - 2\bar{X} \sum_{i=1}^n E(X_i) + nE(\bar{X}^2)) \\
&= \frac{1}{n-1} (\sum_{i=1}^n E(X_i^2) - 2n\bar{X}^2 + nE(\bar{X}^2)) \\
&= \frac{1}{n-1} (nE(X_1^2) - nE(\bar{X}^2)) \\
&= \frac{n}{n-1} (E(X_1^2) - E(\bar{X}^2)) \\
&= \frac{n}{n-1} ((\sigma^2 + \mu) - \frac{\sigma^2}{n} - \mu) \\
&= \frac{n}{n-1} (\sigma^2 - \frac{\sigma^2}{n}) \\
&= \frac{n}{n-1} (\frac{n\sigma^2 - \sigma^2}{n}) \\
&= \sigma^2.
\end{aligned}$$

Por lo que $\hat{\sigma}^2$ es un estimador insesgado de σ^2 . La demostración de la propiedad 3 se puede consultar en Casella y Berger (2002), páginas 218-219, Roussas,G (2003), pagina 189.

1.2.4 Gráfica de Control para la media

Un proceso se considera estable cuando solo causas comunes de variación están actuando en él, causas originadas por la Maquinaria, Mano de Obra, Materiales, Métodos, Medio Ambiente y el Sistema de Medición. Para verificar la estabilidad del proceso es necesario registrar los valores de la característica controlada midiendo y anotando los resultados en una gráfica de control también conocida como gráfica de *Shewhart* en reconocimiento a su inventor Walter A. Shewhart en 1920.

Un objetivo fundamental de las gráficas de control es avisar al personal que opera el proceso que hay causas asignables de variación que están afectando la posición de los datos, su dispersión o ambas, reconociendo esta condición es factible detenerlo para hacer un análisis, identificar las causas, establecer las acciones correctivas y una vez implementadas comenzar nuevamente. Con este tipo de acciones se previene que la calidad del producto manufacturado se deteriore, generando costos de retrabajo y desperdicio.

Para identificar que el proceso pierde su estabilidad en la gráfica se indican **Límites de Control** Superior e Inferior (*LSC*, *LIC*) respectivamente. Para el caso normal (con varianza

conocida) estos límites se representan como

$$LSC = \bar{X} + z \frac{\sigma}{\sqrt{n}}$$

y

$$LIC = \bar{X} - z \frac{\sigma}{\sqrt{n}}.$$

donde z es una constante. Ahora, cuando se desea que la media del proceso sea capturada por los límites de control con una confianza de $1 - \alpha$, la constante z se puede obtener de la siguiente manera:

$$\begin{aligned} P(LIC \leq \mu \leq LSC) &= 1 - \alpha \\ P(\bar{X} - z \frac{\sigma}{\sqrt{n}} \leq \mu \leq \bar{X} + z \frac{\sigma}{\sqrt{n}}) &= 1 - \alpha \\ P(-z \leq \frac{\bar{X} - \mu}{\frac{\sigma}{\sqrt{n}}} \leq z) &= 1 - \alpha. \end{aligned}$$

Entonces, como $\frac{\bar{X} - \mu}{\frac{\sigma}{\sqrt{n}}} \sim N(0, 1)$ se sigue que z es el cuantil $1 - \alpha$ de una normal estándar.

Si por ejemplo se quiere que $1 - \alpha = 0.997365$ entonces de las tablas de la distribución normal estándar se obtiene que $z = 2.79$ por lo que los valores de los límites se encontrarían con:

$$\begin{aligned} LSC &= \bar{x} + \frac{2.79}{\sqrt{n}} \sigma \\ LIC &= \bar{x} - \frac{2.79}{\sqrt{n}} \sigma. \end{aligned}$$

Siendo las expresiones anteriores fórmulas para los cálculos de límites con diferentes tamaños de muestra y valores de la característica estudiada.

En el caso anterior se supone que la varianza es conocida, pero en caso contrario debe emplearse otro procedimiento.

De manera específica, si se supone que X_1, X_2, \dots, X_n son elementos de una muestra aleatoria y que \bar{X} y que $\hat{\sigma}^2$ son su media y varianza. Una posibilidad sería remplazar σ en las fórmulas para varianza conocida con el valor calculado de la varianza de la muestra $\hat{\sigma}$, si el tamaño es relativamente grande ($n > 30$) entonces éste es un procedimiento aceptable.

Cuando el tamaño de la muestra es pequeño como es el caso de una gráfica de control lo anterior no es adecuado y entonces debe emplearse otro procedimiento.

1.2.5 Distribución t student

Para producir un intervalo de confianza válido y suponiendo que la población de interés está distribuida de manera normal, es factible calcularlo a partir de la distribución t de student. De manera específica, sea X_1, X_2, \dots, X_n una muestra aleatoria tomada de una distribución normal con media μ y varianza σ^2 desconocidas, tenemos que la distribución de muestreo de la estadística

$$T = \frac{\bar{X} - \mu}{\hat{\sigma}^2/\sqrt{n}} \quad (1.8)$$

es la distribución t con $n - 1$ grados de libertad. Y lo que nos interesa ahora es comprobar la probabilidad de que:

$$\begin{aligned} P(-t_{\alpha/2, n-1} \leq T \leq t_{\alpha/2, n-1}) &= 1 - \alpha \\ P(-t_{\alpha/2, n-1} \leq \frac{\bar{X} - \mu}{\hat{\sigma}/\sqrt{n}} \leq t_{\alpha/2, n-1}) &= 1 - \alpha \end{aligned}$$

Reacomodando tenemos

$$P(\bar{X} - t_{\alpha/2, n-1} \frac{\hat{\sigma}}{\sqrt{n}} \leq \mu \leq \bar{X} + t_{\alpha/2, n-1} \frac{\hat{\sigma}}{\sqrt{n}}) = 1 - \alpha. \quad (1.9)$$

Si se supone que $n = 5$ y $1 - \alpha = 0.997365$ es decir $\alpha = 0.002635$ de tablas con $n - 1$ grados de libertad y $\alpha/2 = 0.001$ se obtiene $t_{\alpha/2, n-1} = 7.173$, quedando los límites de control de la siguiente manera.

$$\begin{aligned} LSC &= \bar{x} + \frac{7.173}{\sqrt{n}} \hat{\sigma} \\ LIC &= \bar{x} - \frac{7.173}{\sqrt{n}} \hat{\sigma}. \end{aligned}$$

Se puede observar que en general son límites mas amplios que en el caso de varianza conocida.

Debemos resaltar que para el caso de σ conocida el desarrollo del cálculo de límites se fundamenta con el teorema del límite central; mientras que para el caso de σ desconocida se basa en la distribución maestra de una variable aleatoria T .

Sin embargo, el uso de la distribución t es factible si la muestra proviene de una población con distribución normal.

1.2.6 Capacidad y desempeño de un proceso.

Capacidad de Procesos La capacidad del procesos se define generalmente como la habilidad que tiene un proceso de satisfacer las expectativas de los clientes. Cuando un proceso cumple lo anterior se dice que es **capaz**.

Un proceso es capaz cuando en condiciones de estabilidad el 99.73 % de los resultados se encuentran dentro de especificaciones.

Es decir satisface los requerimientos de los clientes a 6σ .

Pero, la dispersión en este contexto tiene doble connotación, ya que la σ puede ser a corto plazo σ_{cp} o a largo plazo σ_{lp} .

¿Que es esto de σ_{cp} y σ_{lp} ?

Variaciones en y entre subgrupos Es importante entender que existen dos tipos de variaciones, la dispersión que se tiene en los datos de un subgrupo y la dispersión que se da entre subgrupos de muestras.

A las variaciones que se dan en el subgrupo se les denomina variaciones de Corto Plazo σ_{cp} esta variación es una **visión optimista** de la dispersión del proceso, por lo regular incluyen causas comunes de variación.

A la variación considerando los distintos subgrupos se le denomina variación a Largo Plazo σ_{lp} , ésta variación es la que el cliente recibe, la variación a largo plazo incluye causas comunes y especiales y por lo general $\sigma_{lp} \geq \sigma_{cp}$.

Cuando un proceso no esta en control

$$\sigma_{lp} \gg \sigma_{cp}.$$

Lo anterior es importante debido a que cuando se habla de capacidad del proceso se desprenden dos componentes; lo que se ha dado en llamar la **capacidad de proceso a corto plazo** representada por C_p y lo que se denomina la **habilidad del proceso a largo plazo**, representada por P_p , y se calculan de la siguiente manera.

Para el caso donde las especificaciones son bilaterales

$LSE \rightarrow$ Limite Superior de Especificacion

y

$LIE \rightarrow$ Limite Inferior de Especificacion

tenemos

$$C_p = \frac{LSE - LIE}{6\hat{\sigma}_{cp}} \quad (1.10)$$

donde $\hat{\sigma}_{cp} = \sqrt{\frac{\sum_{i=1}^n (x_i - \bar{x})^2}{n-1}}$ y n es el tamaño del subgrupo.

La relación anterior se denomina **índice de capacidad potencial del proceso a corto plazo**, esta relación debe tener un valor como mínimo de uno para que el proceso sea capaz de producir un 99.73 % de producto dentro de especificaciones, valores mayores son deseables.

Para el caso a largo plazo lo único que cambia es la estimación de la desviación estándar.

$$\hat{\sigma}_{lp} = \sqrt{\frac{\sum_{i=1}^{kn} (x_i - \hat{\mu})^2}{kn-1}}$$

y

$$\hat{\mu} = \frac{\sum_{i=1}^{kn} x_i}{kn}$$

donde k es la cantidad de subgrupos en la gráfica de control, n es el tamaño del subgrupo y x_i corresponde a las lecturas individuales en cada subgrupo.

Entonces con estos datos se encuentra el **índice de capacidad potencial a largo plazo**.

$$P_p = \frac{LSE - LIE}{6\hat{\sigma}_{lp}}$$

Desempeño de procesos La diferencia entre estos indicadores radica en que con el análisis de capacidad se verifica inicialmente que un proceso tenga la habilidad de generar productos cuya dispersión a 6σ comparada con la tolerancia sea mayor que 1 como mínimo.

Lo anterior no considera posibles cambios en la posición de la media, por tanto un solo indicador no es suficiente para garantizar la capacidad del proceso.

Suponiendo que un proceso esta en control existen tres formas como éste puede fallar en el cumplimiento de las expectativas del cliente.

1. La dispersión del proceso es muy grande.
2. El valor medio del proceso no se encuentra propiamente centrado con respecto a la tolerancia.
3. Las dos anteriores.

Se puede representar de manera gráfica utilizando el símil de una diana para tiro con arco.




Figure 1.1: **Diferencias entre precision y exactitud**

Analizando la Figura 1.1 se pueden ver los distintos resultados de un proceso.

1. La Figura 1.1.1 muestra un conjunto de datos que no son exactos ni precisos.
2. La Figura 1.1.2 muestra resultados que son exactos pero no precisos.
3. En la Figura 1.1.3 tenemos exactitud pero no precisión.
4. Por último la Figura 1.1.4 muestra resultados precisos y exactos.

De lo anterior concluimos que el objetivo debe ser un proceso preciso (dispersión controlada) y exacto (posición controlada).

Muchos indicadores se han creado además de los que se consideran en este capítulo, pero en general C_p , P_p , C_{pk} , P_{pk} son índices adoptados por la industria como los mas prácticos y que permiten tener una idea adecuada del desempeño del proceso.

Anteriormente se presentó cómo se calcula la *capacidad del proceso*, veamos ahora los indicadores que permiten verificar el *desempeño del proceso*.

Para verificar el *desempeño del proceso*, se considera la variación de la posición del valor medio con respecto a cada uno de los límites de especificación.

Utilizando el menor se calcula la habilidad a corto y largo plazo, considerando la dispersión pertinente. (σ_{cp} , σ_{lp})

Procedimiento general para obtención de los indicadores.

1. Identificar el $C_p = \frac{LSE-LIE}{6\hat{\sigma}}$. Donde LSE y LIE corresponden a Límite Superior de Especificación y Límite Inferior de Especificación respectivamente.
2. Tomar una muestra de elementos y encontrar los estadísticos $\bar{x} = \frac{1}{n} \sum_i^n x_i$, la varianza $\hat{\sigma}^2 = \frac{1}{n-1} \sum (x_i - \bar{x})^2$ y la desviación estándar $\hat{\sigma} = \sqrt{\hat{\sigma}^2}$.

3. Se calcula el $C_{pk} = \min \left[\frac{VSE - \bar{x}}{3\hat{\sigma}}, \frac{\bar{x} - VIE}{3\hat{\sigma}} \right]$.
4. EL valor resultante es un indicador de que tan centrado está el proceso,



Figure 1.2:

En la Figura 1.2 se muestran diferentes valores de C_{pk} y como a medida que el valor es mayor que uno el proceso esta mejor centrado y por ende tiene una menor probabilidad de generar no conformes.

Un valor mínimo de 1.33 equivalente a 4σ .

En el punto 2 para los cálculos del *desempeño del proceso* P_{pk} se utiliza la desviación a largo plazo.

1.3 Caso multivariado

1.3.1 Distribución normal multivariada

La distribución normal multivariada es una generalización de la densidad de probabilidad univariada 1.1 para $p \geq 2$, donde el término cuadrático que mide la distancia de x a μ en desviaciones estándar, se puede reescribir de la siguiente manera

$$\left(\frac{x - \mu}{\sigma} \right)^2 = (x - \mu)(\sigma^2)^{-1}(x - \mu) \quad (1.11)$$

Si se representa \mathbf{X} como un vector $p \times 1$ de observaciones de diferentes variables se puede reescribir 1.11 como,

$$(\mathbf{X} - \vec{\mu})^T \Sigma^{-1} (\mathbf{X} - \vec{\mu}) \quad (1.12)$$

Donde el vector $\vec{\mu}$ de dimensión $p \times 1$ representa los valores esperados del vector aleatorio \mathbf{X} , y la matriz Σ de $p \times p$ representa las varianzas-covarianzas de $\mathbf{X} = (X_1, X_2, \dots, X_p)$.

Además, si se supone que Σ es positiva definida, entonces se tiene que la expresión en 1.12 es el cuadrado de la distancia generalizada de \mathbf{X} a $\vec{\mu}$.

La densidad normal multivariada se obtiene remplazando la distancia cuadrática en 1.1 con esta última expresión

$$f(x|\mu, \Sigma) = \frac{1}{|\Sigma|^{1/2} (2\pi)^{p/2}} e^{-\frac{(\mathbf{x}-\vec{\mu})^T \Sigma^{-1} (\mathbf{x}-\vec{\mu})}{2}} \quad (1.13)$$

donde $-\infty < x_i < \infty$, $i = 1, 2, \dots, p$, denotaremos a esta función de densidad *p-dimensional* con $N_p(\vec{\mu}, \Sigma)$.

Vemos en la expresión anterior que la constante de normalización $(\sigma^2)^{-1/2} (2\pi)^{-1/2}$ en 1.1 se cambia por una mas general $|\Sigma|^{1/2} (2\pi)^{p/2}$ que permite que el volumen bajo la superficie de la función normal multivariada sea unitario para cualquier p .

Esto es necesario ya que en el caso multivariado, las probabilidades se representan por volúmenes bajo la superficie sobre regiones definidas en intervalos de valores de x_i .




Figure 1.3: Contorno de densidad constante para distribución normal bivariada con $\sigma_{11} = \sigma_{22}$ y $\sigma_{12} > 0$ o $\rho_{12} > 0$

Densidad normal bivariada A fin de ejemplo mostraremos el desarrollo de la densidad normal bivariada con la finalidad de discutir algunas propiedades de esta.

Sea $p = 2$ y $\mu_1 = E(X_1)$, $\mu_2 = E(X_2)$, $\sigma_{11} = Var(X_1)$, $\sigma_{22} = Var(X_2)$, y $\rho_{12} = \sigma_{12}/(\sqrt{\sigma_{11}}\sqrt{\sigma_{22}}) = Corr(X_1, X_2)$.

Tenemos que

$$\Sigma = \begin{bmatrix} \sigma_{11} & \sigma_{12} \\ \sigma_{21} & \sigma_{22} \end{bmatrix}.$$

y

$$\Sigma^{-1} = \frac{1}{\sigma_{11}\sigma_{22} - \sigma_{12}^2} \begin{bmatrix} \sigma_{22} & -\sigma_{12} \\ -\sigma_{12} & \sigma_{11} \end{bmatrix}$$

Introduciendo el coeficiente de correlación ρ_{12} escribiendo $\sigma_{12} = \frac{\rho_{12}}{\sqrt{\sigma_{11}}\sqrt{\sigma_{22}}}$, se obtiene que $|\Sigma| = \sigma_{11}\sigma_{22} - \sigma_{12}^2 = \sigma_{11}\sigma_{22}(1 - \rho_{12}^2)$, desarrollando la expresión 1.12 se llega a

$$\frac{1}{1 - \rho_{12}^2} \left[\left(\frac{x_1 - \mu_1}{\sqrt{\sigma_{11}}} \right)^2 + \left(\frac{x_2 - \mu_2}{\sqrt{\sigma_{22}}} \right)^2 - 2\rho_{12} \left(\frac{x_1 - \mu_1}{\sqrt{\sigma_{11}}} \right) \left(\frac{x_2 - \mu_2}{\sqrt{\sigma_{22}}} \right) \right] \quad (1.14)$$

Sustituyendo $|\Sigma|$, Σ^{-1} y el resultado 1.14 en 1.13 se obtiene la expresión de la función de densidad normal bivariada con parámetros μ_1 , μ_2 , σ_{11} , σ_{22} y ρ_{12}

$$f(x_1, x_2) = \frac{1}{2\pi\sqrt{\sigma_{11}\sigma_{22}(1-\rho_{12}^2)}} e^{-\frac{1}{1-\rho_{12}^2} \left[\left(\frac{x_1-\mu_1}{\sqrt{\sigma_{11}}} \right)^2 + \left(\frac{x_2-\mu_2}{\sqrt{\sigma_{22}}} \right)^2 - 2\rho_{12} \left(\frac{x_1-\mu_1}{\sqrt{\sigma_{11}}} \right) \left(\frac{x_2-\mu_2}{\sqrt{\sigma_{22}}} \right) \right]} \quad (1.15)$$

Se puede observar en la expresión anterior que si las variables X_1, X_2 no se correlacionan, es decir, $\rho_{12} = 0$, la densidad conjunta se puede escribir como el producto de dos densidades univariadas cada una de la forma 1.1.

Esto es, $f(x_1, x_2) = f(x_1)f(x_2)$ y X_1, X_2 son independientes.

De la expresión 1.12 debe ser claro que la gráfica de los valores de \mathbf{x} generan un elipsoide; Esto es, la función de densidad normal multivariada es constante en superficies donde el cuadrado de la distancia proporcionado por 1.12 es constante. Estas gráficas se les asigna el nombre de *contornos*.

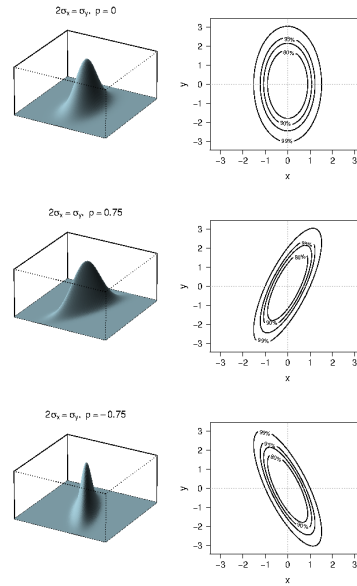


Figure 1.4: Contornos y gráfica de distribución para diferentes valores de ρ y σ . Observe que si $\rho \neq 0$ causa que el ángulo θ que forma el eje mayor de la elipse varíe de acuerdo al signo.

Entonces tenemos que un *contorno de densidad de probabilidad constante* está definido para toda \mathbf{X} tal que $(\mathbf{X} - \vec{\mu})^T \Sigma^{-1} (\mathbf{X} - \vec{\mu}) = c^2$, y representa la superficie generada por el elipsoide centrado en $\vec{\mu}$.

En la grafica anterior se ven ejemplos para probabilidades de $(1 - \alpha) = 0.99, 0.90, 0.80$.

Los ejes de las elipsoides están dirigidos en el sentido dado por los vectores característicos de Σ^{-1} , y las longitudes son proporcionales al reciproco de la raíz cuadrada de los valores característicos.

Afortunadamente, es factible evitar el calculo de Σ^{-1} ya que también se pueden encontrar la dirección y el sentido de los ejes de la elipsoide usando los valores y vectores característicos de Σ .

Esto es ya que si, Σ es *positiva definida* existe su inversa Σ^{-1} y se satisface que:

$$\Sigma \vec{e} = \lambda \vec{e} \quad \text{lo que implica} \quad \Sigma^{-1} \vec{e} = \frac{1}{\lambda} \vec{e}$$

así que los valores y vectores característicos de $\Sigma \rightarrow (\lambda, \vec{e})$, corresponden a los valores y vectores característicos de $\Sigma^{-1} \rightarrow (\frac{1}{\lambda}, \vec{e})$, donde Σ^{-1} también es *positiva definida*.

Tenemos entonces que continuando el caso bivariado, para encontrar los ejes del contorno dada una función bivariada de probabilidad constante cuando $\sigma_{11} = \sigma_{22}$, se obtienen los valores y vectores característicos siguientes, (ver Applied Multivariate Statistical Analysis Richard A. Johnson, Dean W. Wichern, 2007. página 154).

$$\lambda_1 = \sigma_{11} + \sigma_{12} \text{ y } \vec{e}_1 = \left[\frac{1}{\sqrt{2}}, \frac{1}{\sqrt{2}} \right]^T$$

De igual manera

$$\lambda_2 = \sigma_{11} - \sigma_{12} \text{ y } \vec{e}_2 = \left[\frac{1}{\sqrt{2}}, -\frac{1}{\sqrt{2}} \right]^T$$

Si la covarianza σ_{12} (o correlación ρ_{12}) es positiva, λ_1 es el mayor valor característico cuyo vector característico es paralelo al eje formando un ángulo positivo respecto del lado positivo del eje x y que además pasa por el punto $\vec{\mu} = [\mu_1, \mu_2]$. Esto es cierto para cualquier valor positivo de la covarianza (correlación). Dado que los ejes de los contornos están dados por $\pm c\sqrt{\lambda_1} \vec{e}_1$ y $\pm c\sqrt{\lambda_2} \vec{e}_2$, y los vectores característicos son unitarios, el eje mayor está asociado con el vector característico mayor. Dea ahí que, para variables aleatorias normales correlacionadas positivamente, el eje mayor de la *elipse de densidad constante* coincide con una línea a 45 grados que pasa por $\vec{\mu}$. (Ver Figura 1.4)




Figure 1.5: Contorno de densidad constante para distribución normal bivariada con $\sigma_{11} = \sigma_{12}$ y $\sigma_{12} > 0$

Si el coeficiente de correlación ρ_{12} es negativo, $\lambda_2 = \sigma_{11} - \sigma_{12}$ es el vector de mayor valor, por lo que el eje principal de la elipsoide de probabilidad constante se inclinara a 135 grados del lado positivo del eje x y pasará po el punto $\vec{\mu}$.

Debido a que los contornos de densidad constante de función de distribución normal p -dimensional, son elipsoides definidos por \mathbf{X} tales que

$$(\mathbf{X} - \vec{\mu})^T \Sigma^{-1} (\mathbf{X} - \vec{\mu}) = c^2 \quad (1.16)$$

y estos elipsoides están centrados en $\vec{\mu}$ con ejes $\pm c\sqrt{\lambda_i} \vec{e}_i$,

Podemos concluir que:

Sea \mathbf{X} una variable aleatoria distribuida $N_p(\mu, \Sigma)$ con $|\Sigma| > 0$ entonces:

1. $(\mathbf{X} - \vec{\mu})^T \Sigma^{-1} (\mathbf{X} - \vec{\mu})$ se distribuye como una distribución χ_p^2 con p grados de libertad.
2. La distribución $N_p(\mu, \Sigma)$ asigna una probabilidad $(1-\alpha)$ al elipsoide $X \mid (\mathbf{X} - \vec{\mu})^T \Sigma^{-1} (\mathbf{X} - \vec{\mu}) \leq \chi_{p(\alpha)}^2$, donde $\chi_{p(\alpha)}^2$ denota el (100α) percentil de la distribución.

En la siguiente figura se pueden ver los contornos constantes de densidad de probabilidad para los casos donde la probabilidad bajo la superficie normal bivariada es 50% y 90% respectivamente.




Figure 1.6: Contorno de densidad constante para 50% y 90% de probabilidad

La distribución normal p variada tiene su valor máximo cuando el cuadrado de la distancia en 1.15 es cero, es decir cuando $\mathbf{X} = \vec{\mu}$. Por lo que $\vec{\mu}$ es el punto de máxima densidad o *moda*, así como el valor esperado de \mathbf{X} o *media*. El hecho de que $\vec{\mu}$ es la media de una distribución normal multivariada se sigue de la simetría exhibida por los contornos de densidad constante que están centrados y balanceados en $\vec{\mu}$.

Muestreo de una distribución normal multivariada Al tomar muestras de una población normal multivariada la única fuente de información son los datos tomados en sitio. Inferencias estadísticas son por tanto la forma adecuada para extraer conclusiones sobre la población multivariada.

En inferencia estadística los datos tomados de la muestra se procesan matemáticamente para encontrar estadísticos. La distribución de probabilidad de un estadístico se conoce como distribución de muestreo.

Para la distribución normal multivariada, se tienen dos estadísticos importantes, la media \bar{X} y la matriz de covarianzas \mathbf{S}

Distribuciones de muestreo de \bar{X} y de \mathbf{S} Sea $\mathbf{X}_1, \mathbf{X}_2, \dots, \mathbf{X}_n$ una muestra aleatoria tomada de una población normal donde la distribución de la variable aleatoria $\mathbf{X} \sim N_p(\vec{\mu}, \Sigma)$ que determina completamente la distribución de muestreo de \bar{X} y de \mathbf{S} .

Usando ahora el caso univariado donde $\bar{x} \sim N(\mu, \sigma^2)$ para presentar los resultados de \bar{X} y de \mathbf{S}

En el caso univariado ($p = 1$) donde \bar{x} se distribuye normal con media μ y varianza $\frac{1}{n}\sigma^2 = \frac{\text{varianza población}}{\text{tamaño de la muestra}}$

El resultado para $p \geq 2$ es análogo en que \bar{X} tiene una distribución normal con media $\vec{\mu}$ y covarianza $\frac{1}{n}\Sigma$.

Para el caso univariado recordemos que la varianza de una muestra es $(n-1)s^2 = \sum_{j=1}^n (x_j - \bar{x})^2$ y se distribuye como σ^2 veces una variable aleatoria χ^2 con $n-1$ grados de libertad.

Por lo que para el caso multivariado se tiene que $(n-1)S^2$ se distribuye como $\sigma^2 * [(Z_1^2 + Z_2^2 + \dots + Z_{n-1}^2)] = (\sigma, Z_1)^2 + \dots + (\sigma, Z_{n-1})^2 \sim \sigma^2 \chi_{n-1}^2$. Los términos σZ_i se distribuyen de forma independiente con distribución $N(0, \sigma^2)$. Es ésta última expresión la que se puede generalizar de forma adecuada a una función de distribución para la matriz de covarianzas de la muestra.

La distribución de muestreo de la matriz de covarianza (Σ) de la muestra esta definida como una distribución *Wishart*. Específicamente, $W_{n-1}(S|\Sigma)$ es una distribución Wishart con $n-1$ grados de libertad. Es decir.

$W_m(S|\Sigma) = \text{distribución de } \sum_{j=1}^m Z_j Z_j^T$
donde $Z_j \sim N_p(0, \Sigma)$

Resumiendo tenemos:

Sea $\mathbf{X}_1, \mathbf{X}_2, \dots, \mathbf{X}_n$ una muestra aleatoria de tamaño n de una distribución normal *p-variada* con media $\vec{\mu}$ y matriz de covarianza Σ .

1. $\bar{\mathbf{X}}$ se distribuye como $N_p(\vec{\mu}, \Sigma)$
2. $(n-1)S$ se distribuye como una *matriz aleatoria Wishart* con $n-1$ grados de libertad.
3. $\bar{\mathbf{X}}$ y S son independientes.

Teorema del límite central aplicado a muestras multivariadas Sea $\bar{\mathbf{X}}$ el vector de medias y S la matriz de covarianzas tomadas de una población con distribución $\mathbf{X} \sim N_p(\vec{\mu}, \Sigma)$

Además cuando $n \rightarrow \infty$

1. $\lim_{n \rightarrow \infty} \bar{\mathbf{X}} = \vec{\mu}$
2. $\lim_{n \rightarrow \infty} S = \Sigma$
3. $\sqrt{n}(\bar{\mathbf{X}} - \vec{\mu}) \sim N_p(\mathbf{0}, \Sigma)$
4. $n(\bar{\mathbf{X}} - \vec{\mu})^T \mathbf{S}^{-1} n(\bar{\mathbf{X}} - \vec{\mu}) \rightarrow n(\bar{\mathbf{X}} - \vec{\mu})^T \Sigma^{-1} n(\bar{\mathbf{X}} - \vec{\mu}) \sim \chi_p^2$

Donde la última ecuación sirve como base para determinar los límites de control para gráficas multivariadas.

En aplicaciones prácticas si

1. $(n-p) > 40$ (muestras grandes), la ecuación en el inciso 4 es la adecuada.

2. $(n - p) < 40$ (muestras pequeñas) la distribución $n(\bar{\mathbf{X}} - \vec{\mu})^T \mathbf{S}^{-1} n(\bar{\mathbf{X}} - \vec{\mu}) \sim \frac{p(n-1)}{n-p} F_{p, n-p}$ es la adecuada.

Existen dos grandes tareas en inferencia estadística

- Estimación de parámetros
- Prueba de Hipótesis

Para la estimación de parámetros se usa la información proporcionada por una muestra de la población, específicamente se diseñan estimadores que permiten inferir valores de los parámetros de la población.

Existen dos tipos de estimadores. Estimadores puntuales.- Es la mejor estimación del parámetro. Intervalos de confianza.- Son los intervalos en los que se tiene una probabilidad (nivel de confianza) $(1 - \alpha)$ de que el parámetro de interés se encuentre encajonado.

Prueba de hipótesis sobre la media (muestras pequeñas) Sea $\mathbf{X} \sim N_p(\mu, \Sigma)$

si se toma una muestra pequeña $n - p < 40$ y se calcula $\bar{\mathbf{X}}$ y S , se quiere probar que:

$$H_0 : \vec{\mu} = \vec{\mu}_0 \text{ y que } H_1 : \vec{\mu} \neq \vec{\mu}_0$$

Regla de decisión

No aceptar H_0 si $T_0^2 > T_c^2$ donde T_c^2 es el valor crítico.

Para verificar la prueba se usa:

$$T_0^2 = n(\bar{\bar{\mathbf{X}}} - \vec{\mu}_0)^T S^{-1} n(\bar{\bar{\mathbf{X}}} - \vec{\mu}_0) > \frac{p(n-1)}{n-p} F_{p, n-p} = T_c^2.$$

Prueba de hipótesis sobre la media (muestras grandes) De igual manera, sea $\mathbf{X} \sim N_p(\mu, \Sigma)$ se toma una muestra grande $n - p > 40$ y se calcula $\bar{\mathbf{X}}$ y \mathbf{S} , se quiere probar que:

$$H_0 : \vec{\mu} = \vec{\mu}_0 \text{ y que } H_1 : \vec{\mu} \neq \vec{\mu}_0$$

Para realizar la prueba se usa:

$$T_0^2 = n(\bar{\bar{\mathbf{X}}} - \vec{\mu}_0)^T \mathbf{S}^{-1} n(\bar{\bar{\mathbf{X}}} - \vec{\mu}_0) \sim \chi_p^2$$

Cuando H_0 no es verdadera, el valor estimado de $T_0^2 > \chi_p^2 = T_c^2$

en los dos casos anteriores se puede ver que la diferencia principal es la distribución del estadístico T_c^2 con la que se compara, ya que si el tamaño de muestra es:

- Grande $T_c^2 \sim \chi_p^2$
- Pequeña $T : c^2 \sim \frac{p(n-1)}{n-p} F_{\alpha, p, n-p}$

Control Estadístico del Proceso (caso multivariado) En la práctica las variables a controlar en un proceso son de naturaleza multivariada, por ejemplo, en una operación de ensamble de la carrocería de un automóvil existen muchas variables en la mayoría de los casos correlacionadas, igualmente en algunos procesos químicos variables tales como la temperatura, presión y concentración son multivariadas y altamente correlacionadas.

Monitorear dos características independientemente nos puede conducir a errores, veamos las siguientes gráficas de control.

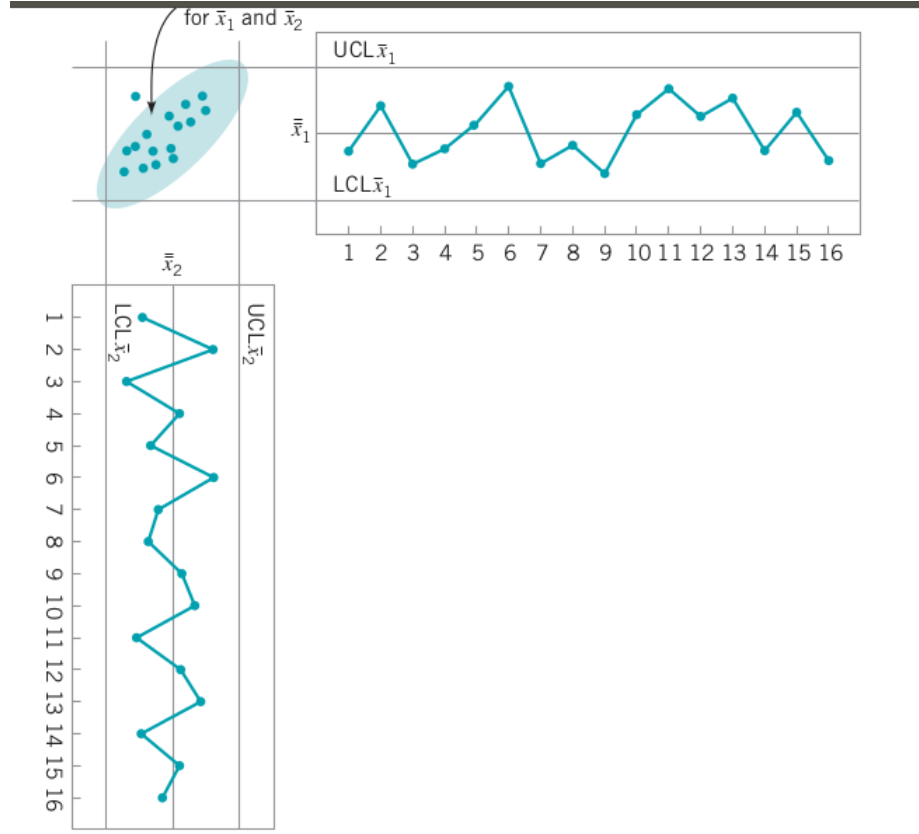


Figure 1.7: Gráficas de control superpuestas de dos variables dependientes

Se puede observar en la grafica como dos variables independientes controladas con dos graficas y que al compararlas simultaneamente se puede observar el comportamiento inusual de uno de los puntos.

Lo anterior si analizamos probabilidades confirma la condicion de inestabilidad de uno de los puntos independientemente d lo que las graficas individuales puedan mostrar.

Una grafica de control cuando se verifica una característica tiene una probabilidad de 0.0027 de que un punto esté fuera de límites de control $\pm 3\sigma$, y mas aún si las variables son independientes la probabilidad de que tanto \bar{x}_1 como \bar{x}_2 esten fuera es de control suponiendo que el proceso es estable es $(0.0027)(0.0027) = 0.00000729$ valor que es mucho menor que 0.0027. De ahí que la probabilidad de que tanto \bar{x}_1 como \bar{x}_2 esten dentro de los límites es $(0.9973)(0.9973) = 0.99460729$. Por lo que el uso de dos diferentes graficos de control ha distorsionado los resultados y por tanto el error tipo I y la probabilidad de que un punto este dentro de límites no es igual a la que debiese ser.

Esta distorsión se asentúa cuando se incrementa el número de características graficadas, en general si existen p características estadísticamente independientes y si una gráfica de control con Perror Tipo I = α entonces la probabilidad de error del conjunto se puede estimar como:

$$\alpha' = 1 - (1 - \alpha)^p \quad (1.17)$$

y la probabilidad de que p medias simultaneamente esten dentro de límites es.

$$P(\text{p medias dentro de control}) = (1 - \alpha)^p \quad (1.18)$$

Claramente la distorsión en este procedimiento es severa, aún para valores moderados de p .

Además las características p graficadas, son dependientes, que en realidad es muy común si se toman sobre el mismo producto las ecuaciones y no son válidas y la probabilidad conjunta entonces es muy difícil de estimar.

Este tipo de control donde mas de una característica de calidad se necesita controlar se llama **Control de Calidad Multivariado**. Dentro de los primeros investigadores se encuentra Hotteling (1947) que aplicó sus procedimientos al control de la detección de

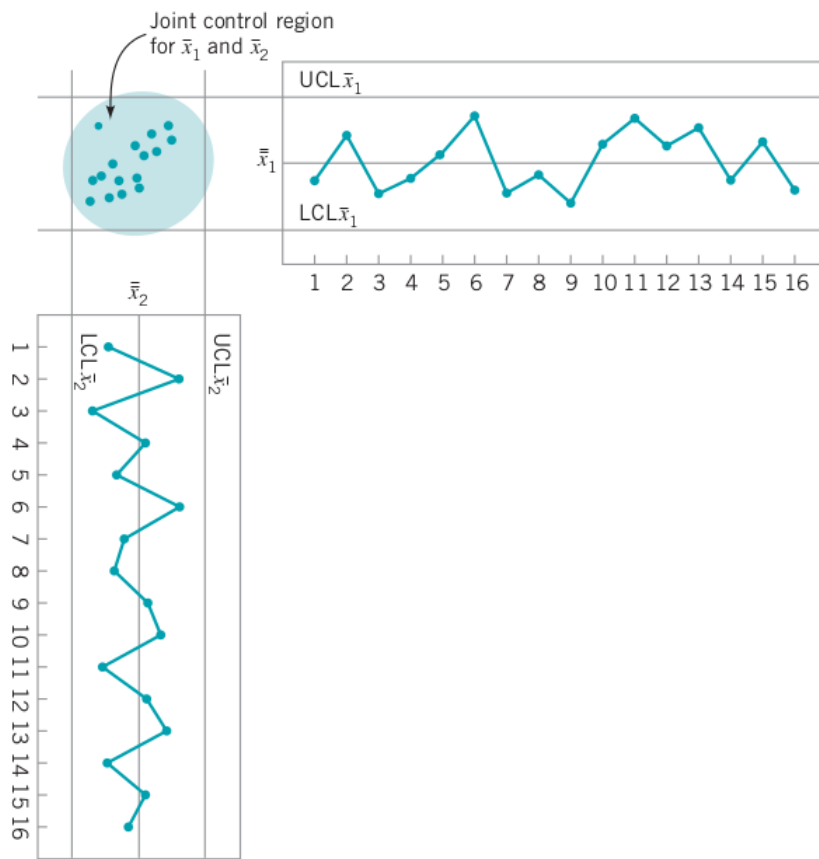


Figure 1.8: Gráfica de control de control dos variables independientes)

Usualmente para controlar estas variables se desarrollan gráficas individuales que pueden en su operación confundir a los operadores y por consecuencia llevar a desiciones equivocadas.

Para apoyar al control de procesos multivariados se puede utilizar el estadístico T de hotelling. Con el se pueden desarrollar gráficas de control multivariadas. Sin embargo como los cálculos asociados son complicados y requieren conocimiento de álgebra de matrices, su implementación ha sido lenta.

Actualmente se han incorporado a los procesos herramientas de cómputo que facilitan los cálculos y es por esa razón que es factible actualmente llevar a cabo la operación de gráficas de control con base en el estadístico T^2 .

Gráfica de control para la media Sea $X = (X_1, X_2, \dots, X_p)$ un vector de variables que caracteriza la operación del proceso, y sea $X \sim N_p(\mu, \Sigma)$, donde $\bar{\mu} = (E(X_1), E(X_2), \dots, E(X_p))^T = (\mu_1, \mu_2, \dots, \mu_p)$ el vector de medias y S la matriz de covarianzas.

Dado lo anterior suponemos que la operación del proceso es estable, nos interesa en intervalos específicos comprobar que:

$$H_0 : \bar{\mu} = \bar{\mu}_0 \text{ y que } H_1 : \bar{\mu} \neq \bar{\mu}_0$$

donde H_0 implica que el proceso esta en condiciones de operación normal.

Para probar la hipótesis se toma un subgrupo de mediciones de las distintas variables de tamaño $(n - p < 40)$ quedando como.

$$X_{n \times p} = \begin{bmatrix} X_{11} & X_{12} & \cdots & X_{1p} \\ X_{21} & X_{22} & \cdots & X_{2p} \\ \cdots & \cdots & \cdots & \cdots \\ X_{n1} & X_{n2} & \cdots & X_{np} \end{bmatrix}$$

$$\bar{X} = \begin{bmatrix} \bar{X}_1 \\ \bar{X}_2 \\ \cdots \\ \bar{X}_p \end{bmatrix}$$

Donde \bar{X} es el estimador de $\bar{\mu}$, calculando

$T_M^2 = n(\bar{X} - \vec{\mu}_0)^T S^{-1} (\bar{X} - \vec{\mu}_0)$ donde T_M^2 es el estadístico T^2 para los estimadores puntuales \bar{X} , S calculados con los datos de la población con distribución $N_p(\mu, \Sigma)$.

Se vió anteriormente que si $\bar{\mu} = \bar{\mu}_0$ el estadístico T_M^2 sigue una distribución,

$$F_0 = \frac{n-1}{p(n-1)} T_M^2 \sim F_{p, n-p}$$

donde n es el número de observaciones para calcular la matriz de covarianza S .

Cuando $\bar{\mu} \neq \bar{\mu}_0$, F_0 tendrá una distribución F no centrada y su valor será significativamente mayor, por lo que es probable que $F_0 > F_{\alpha, p, n-p}$, por lo que el límite superior de control (LSC) para T_M^2 es

$$LSC = \frac{n-1}{p(n-1)} F_{\alpha, p, n-p}$$

Si T_M^2 excede el LSC no es posible afirmar que el proceso está en operación estable (H_0), indicando que causas asignables deben ser evaluadas.




Figure 1.9: Gráfica de control χ^2 para LSC. (muestra grande)

Descomposición de T^2